Seu celular sabe o que você está fazendo?

Clustering de dados e detecção de comunidades em grafos

Francisco Eduardo Fontenele (15452569)
Vinicius Botte (15522900)

Projeto 2 | Outubro de 2026

Os dados: 30 pessoas, um celular na cintura

Cada voluntário (19 a 48 anos) fez seis atividades com um Samsung Galaxy S II preso à cintura.

O acelerômetro e o giroscópio foram lidos 50 vezes por segundo e o sinal foi cortado em janelas de 2,56 s.

De cada janela saem 561 números: médias, desvios, energia, frequências etc.

Cada janela tem um rótulo: a atividade que a pessoa fazia (anotada por vídeo).

10.299
janelas (objetos)

561
atributos por janela

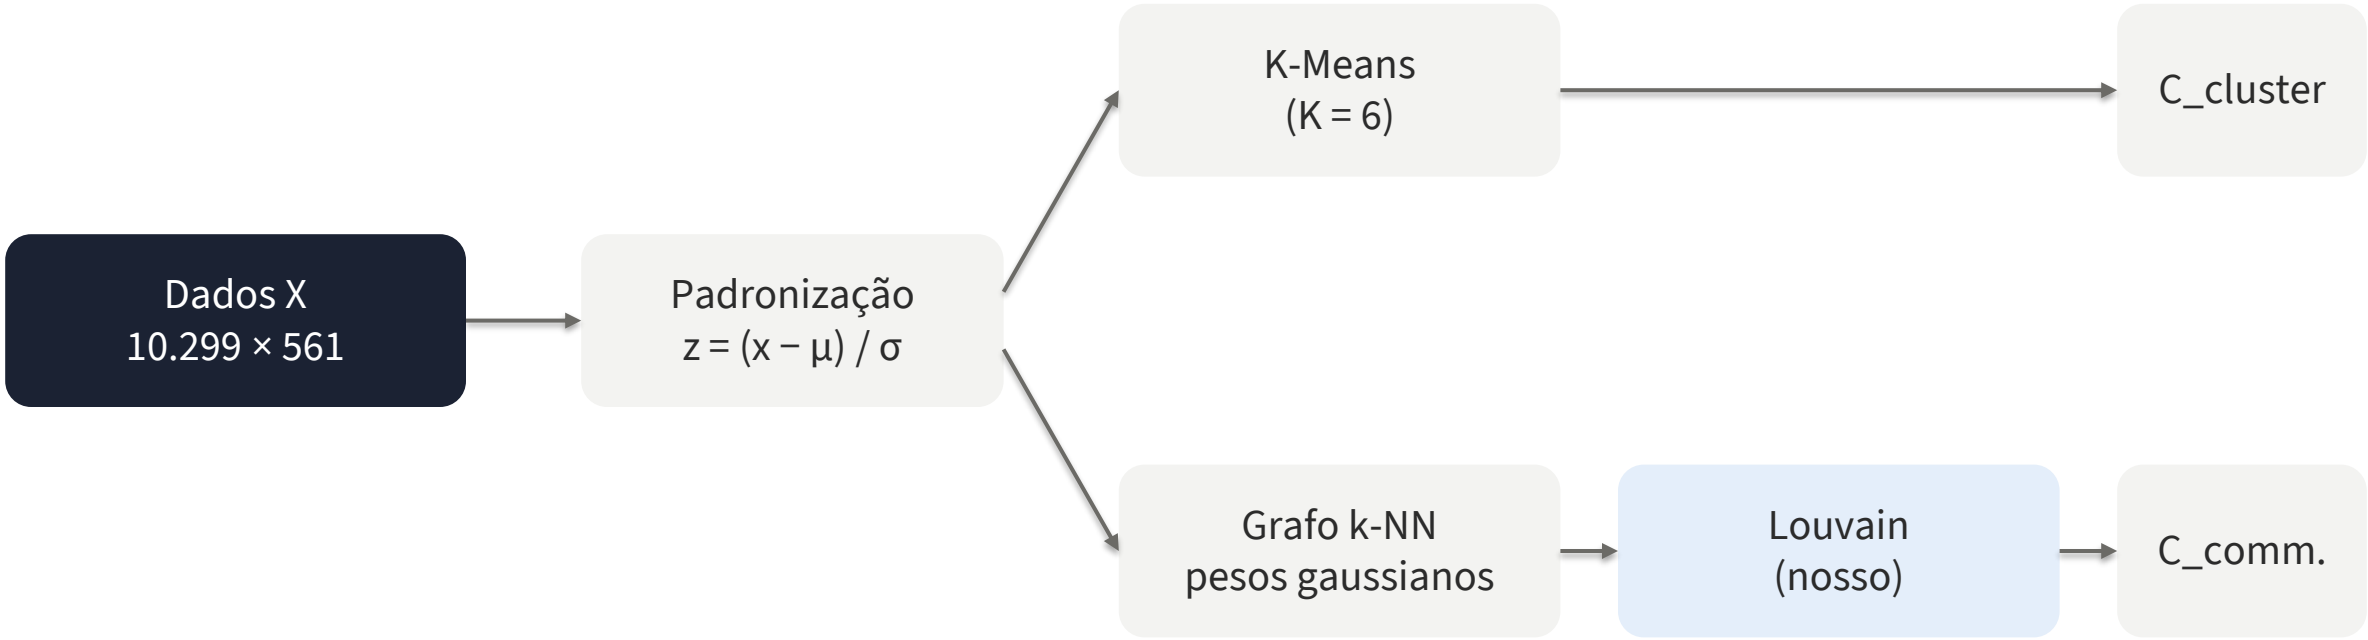
6
atividades (rótulos)

30
voluntários

Andando · Subindo escada · Descendo escada
Sentado · Em pé · Deitado

Fonte: UCI Machine Learning Repository (Reyes-Ortiz et al., 2013), licença CC BY 4.0

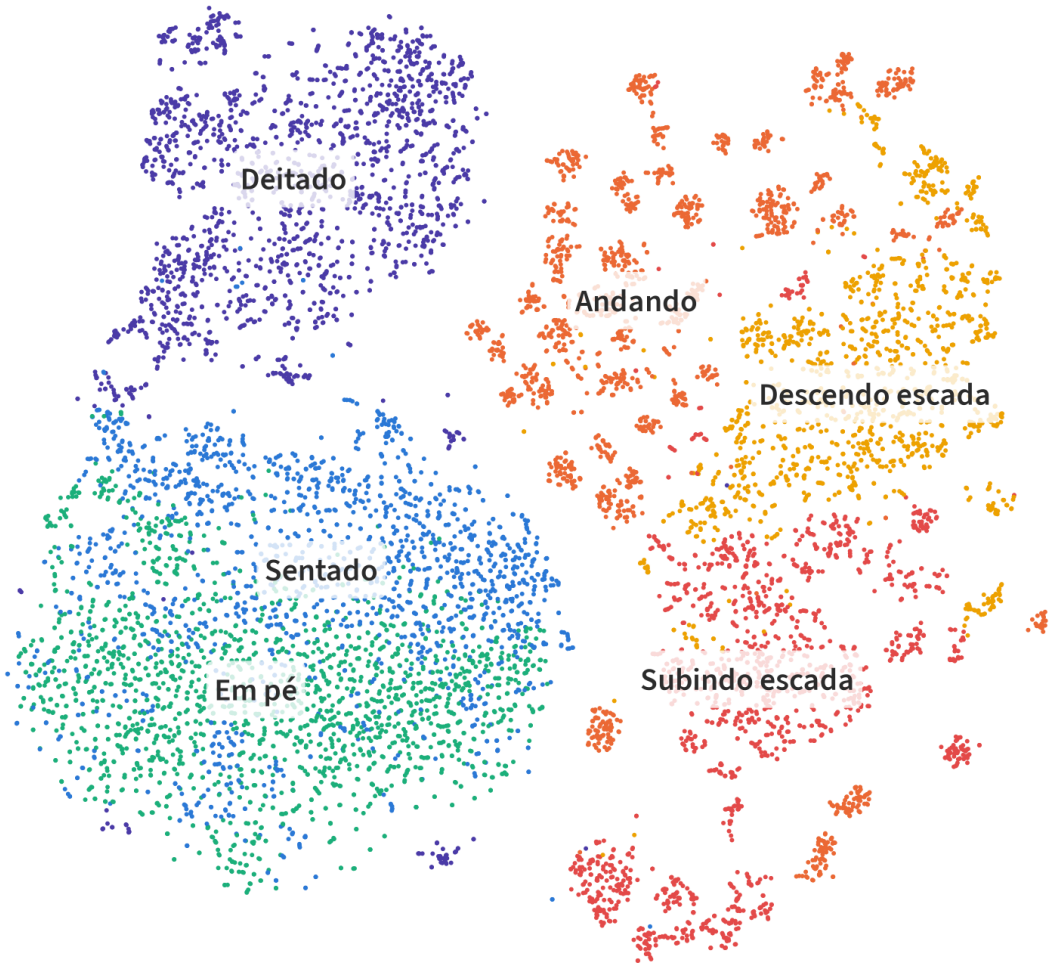
Mesmos dados, duas representações



Comparação: ARI e NMI entre C_cluster, C_community e as atividades reais

Como os dados se parecem

10.299 janelas de sensor, coloridas pela atividade real



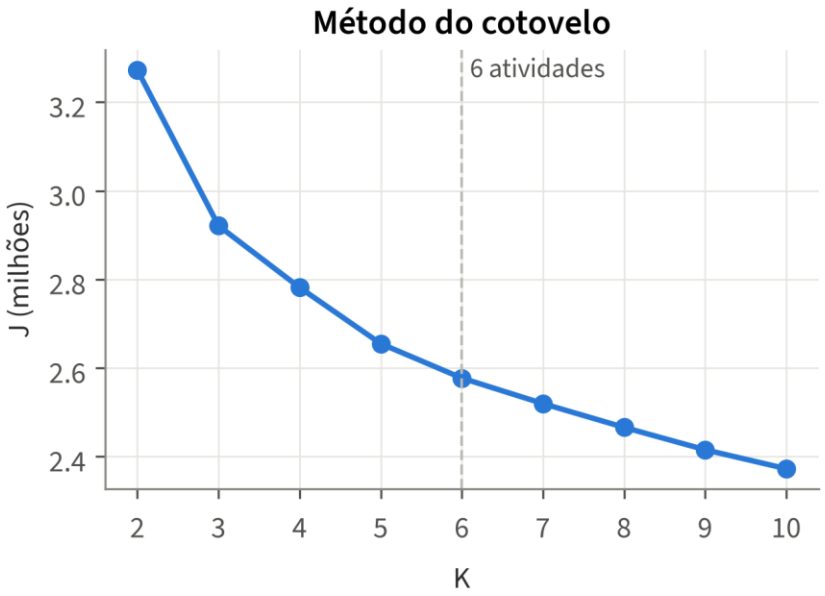
Projeção t-SNE: 561 dimensões viram 2, só para desenhar. Os algoritmos usam os 561 atributos.

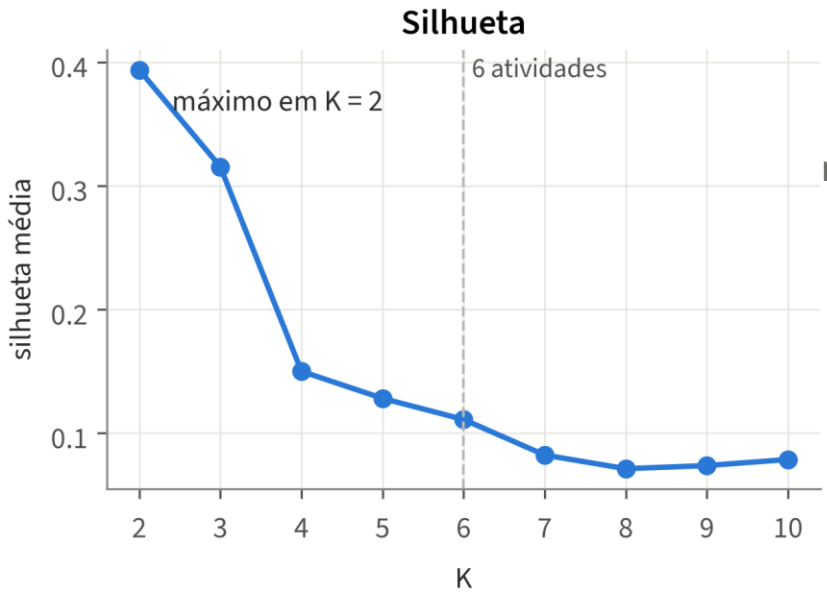
Em movimento (direita) e parado (esquerda) ficam bem separados.

Sentado e Em pé se misturam: o celular na cintura quase não vê diferença.

Andando aparece em várias ilhas pequenas. Guardem isso.

K-Means: quantos grupos?





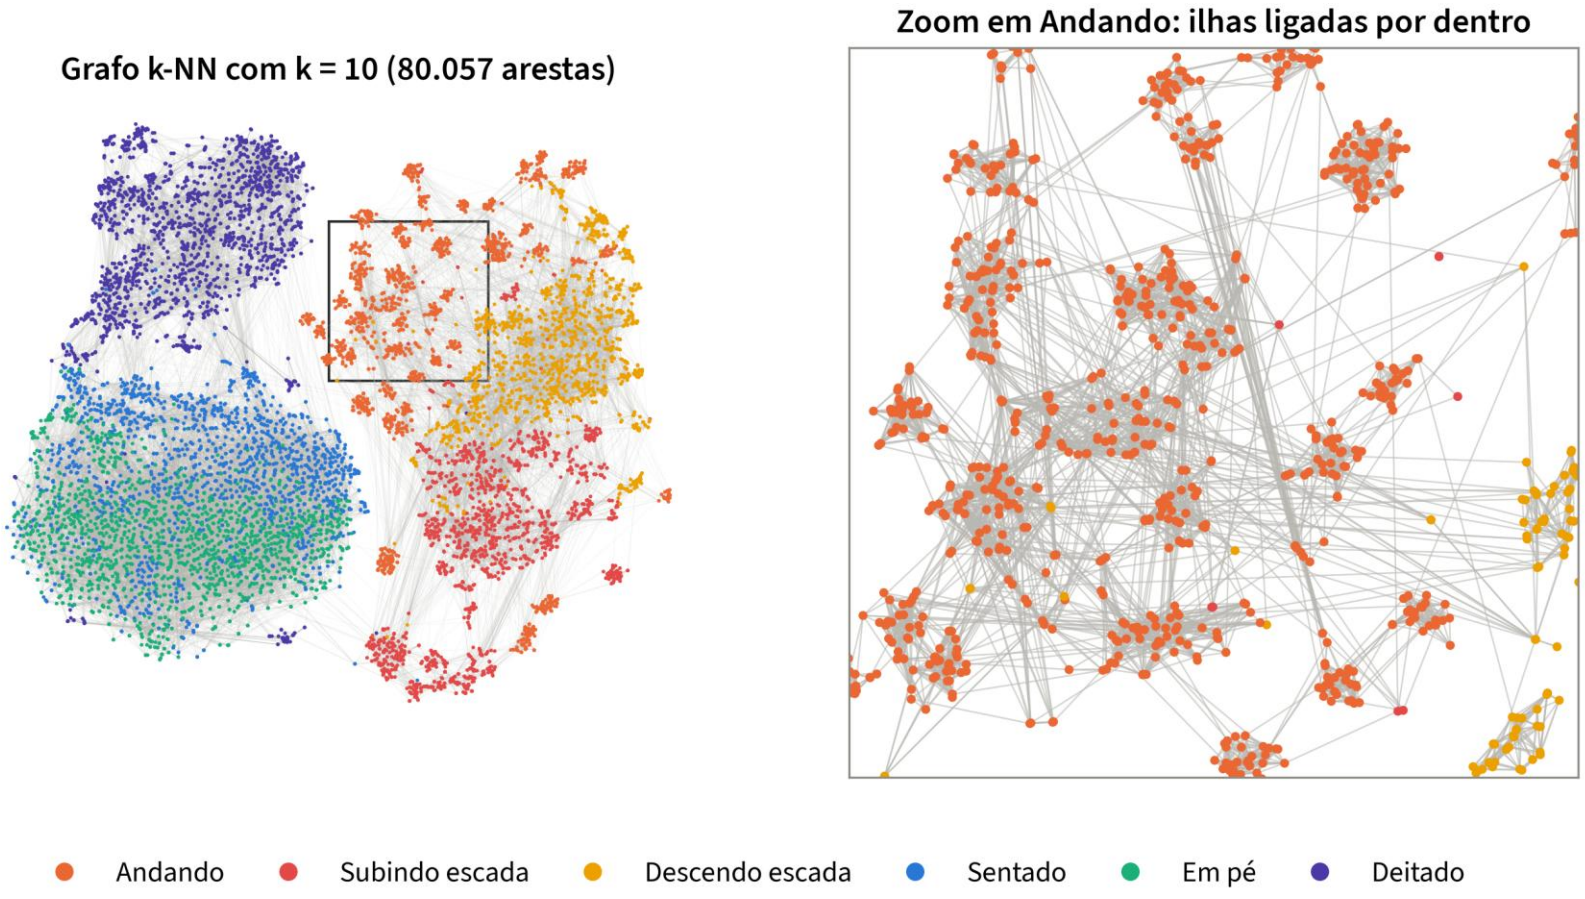
K = 2

maior silhueta (0,39)

Com K = 2 o K-Means separa "em movimento" de "parado" quase perfeitamente (ARI = 0,99 com essa divisão).

O cotovelo não tem um ponto claro. Usamos K = 6, o número de atividades, para comparar com os rótulos.

O grafo k-NN



Cada janela é um vértice, ligada às suas k vizinhas mais próximas (distância euclidiana).

Grafo simétrico: basta um dos dois ser vizinho do outro.

Peso da aresta: $w = \exp(-d^2 / 2\sigma^2)$, com σ = mediana das distâncias aos vizinhos.

No zoom: cada ilha de Andando é bem ligada por dentro e quase não se liga às outras.

Louvain, implementado por nós

1. Mover vértices

Cada vértice vai para a comunidade vizinha que mais aumenta a modularidade Q.

Repete até ninguém mais mudar.

2. Agregar

Cada comunidade vira um único vértice; arestas entre comunidades somam seus pesos.

Volta ao passo 1 no grafo menor, até Q parar de subir.

Grafo	Q (nosso)	Q (networkx)
Karatê (Zachary)	0,420	0,420
kNN k=3	0,841	0,841
kNN k=5	0,807	0,808
kNN k=10	0,785	0,787
kNN k=15	0,770	0,765
kNN k=20	0,748	0,751

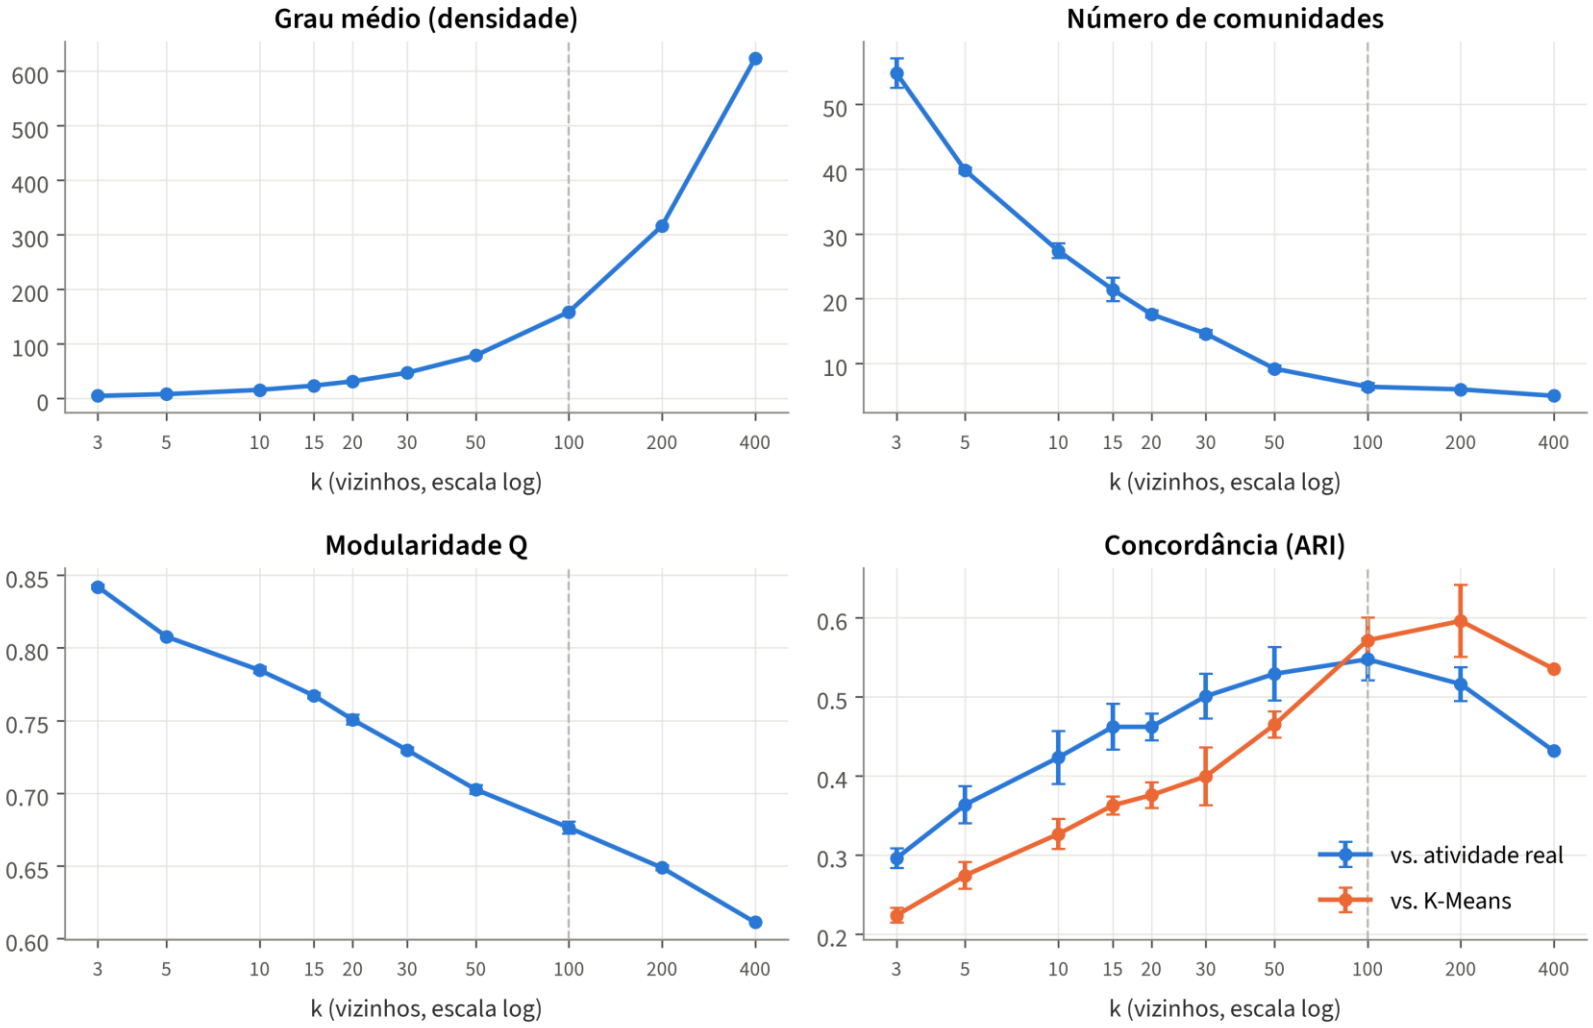
Validação: mesma modularidade da biblioteca (e partição idêntica no karatê).

Experimento: variando k

k	Grau médio	Comunidades	Modularidade Q	ARI	NMI
3	4,6	54,8 ± 2,3	0,842 ± 0,001	0,296 ± 0,012	0,579 ± 0,006
5	7,7	39,8 ± 0,4	0,808 ± 0,001	0,363 ± 0,023	0,598 ± 0,014
10	15,5	27,4 ± 1,1	0,785 ± 0,002	0,423 ± 0,034	0,629 ± 0,018
15	23,3	21,4 ± 1,8	0,767 ± 0,002	0,462 ± 0,029	0,651 ± 0,022
20	31,2	17,6 ± 0,5	0,751 ± 0,004	0,462 ± 0,017	0,648 ± 0,008
30	47,0	14,6 ± 0,5	0,730 ± 0,002	0,500 ± 0,029	0,661 ± 0,012
50	78,8	9,2 ± 0,4	0,703 ± 0,003	0,529 ± 0,034	0,663 ± 0,010
100	158,5	6,4 ± 0,5	0,676 ± 0,004	0,547 ± 0,026	0,660 ± 0,018
200	316,2	6,0 ± 0,0	0,649 ± 0,002	0,516 ± 0,021	0,636 ± 0,015
400	623,3	5,0 ± 0,0	0,611 ± 0,000	0,431 ± 0,000	0,624 ± 0,001

ARI e NMI comparam as comunidades com as atividades reais. Média ± desvio-padrão em 5 sementes.

O que k muda



k pequeno (3 a 5)

Dezenas de comunidades. Q alto, mas os grupos são pedaços de atividades.

k = 100 (escolhido)

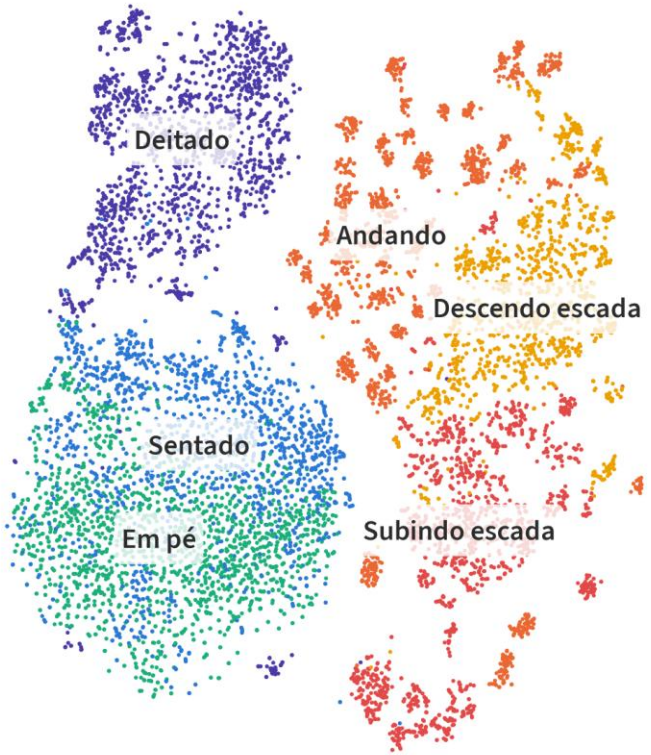
Cerca de 6 comunidades e o maior ARI com as atividades (0,55).

k muito grande (400)

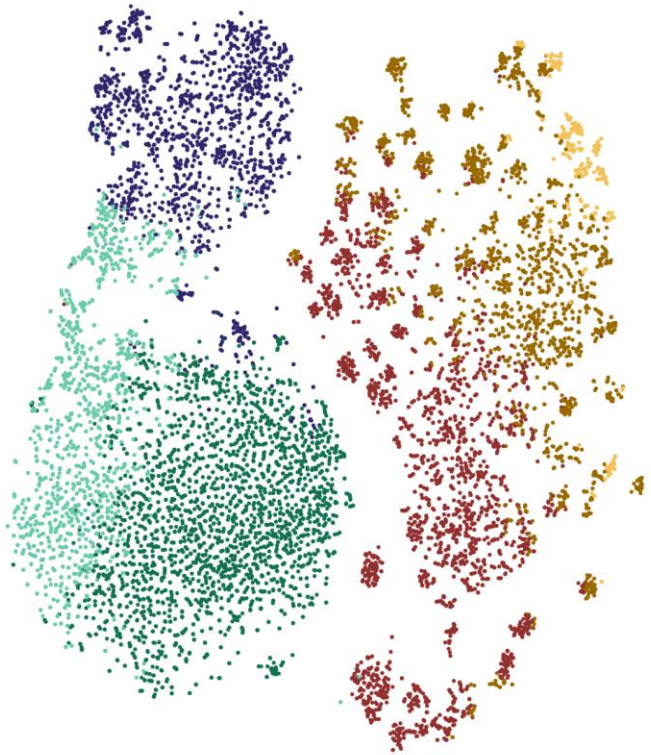
As três atividades em movimento viram uma comunidade só. O ARI cai.

Atividade real × K-Means × comunidades

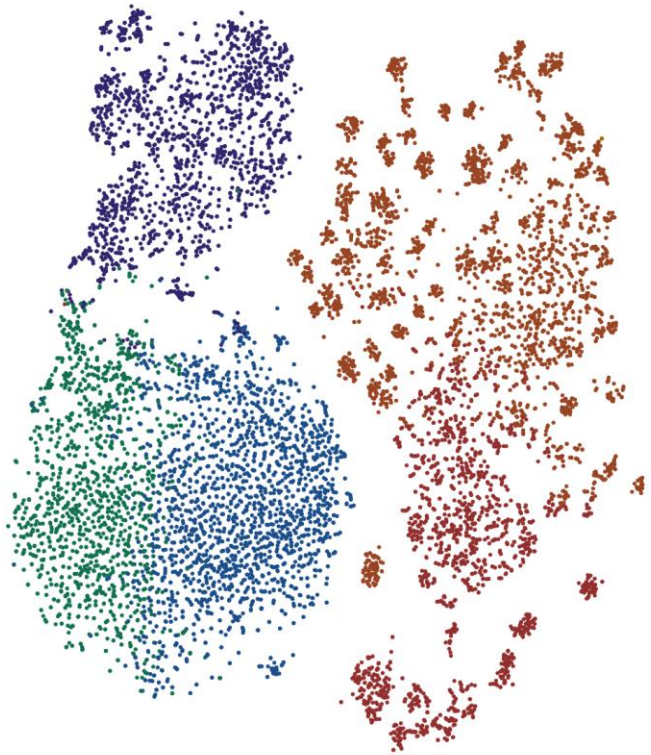
Atividade real



K-Means (K = 6)

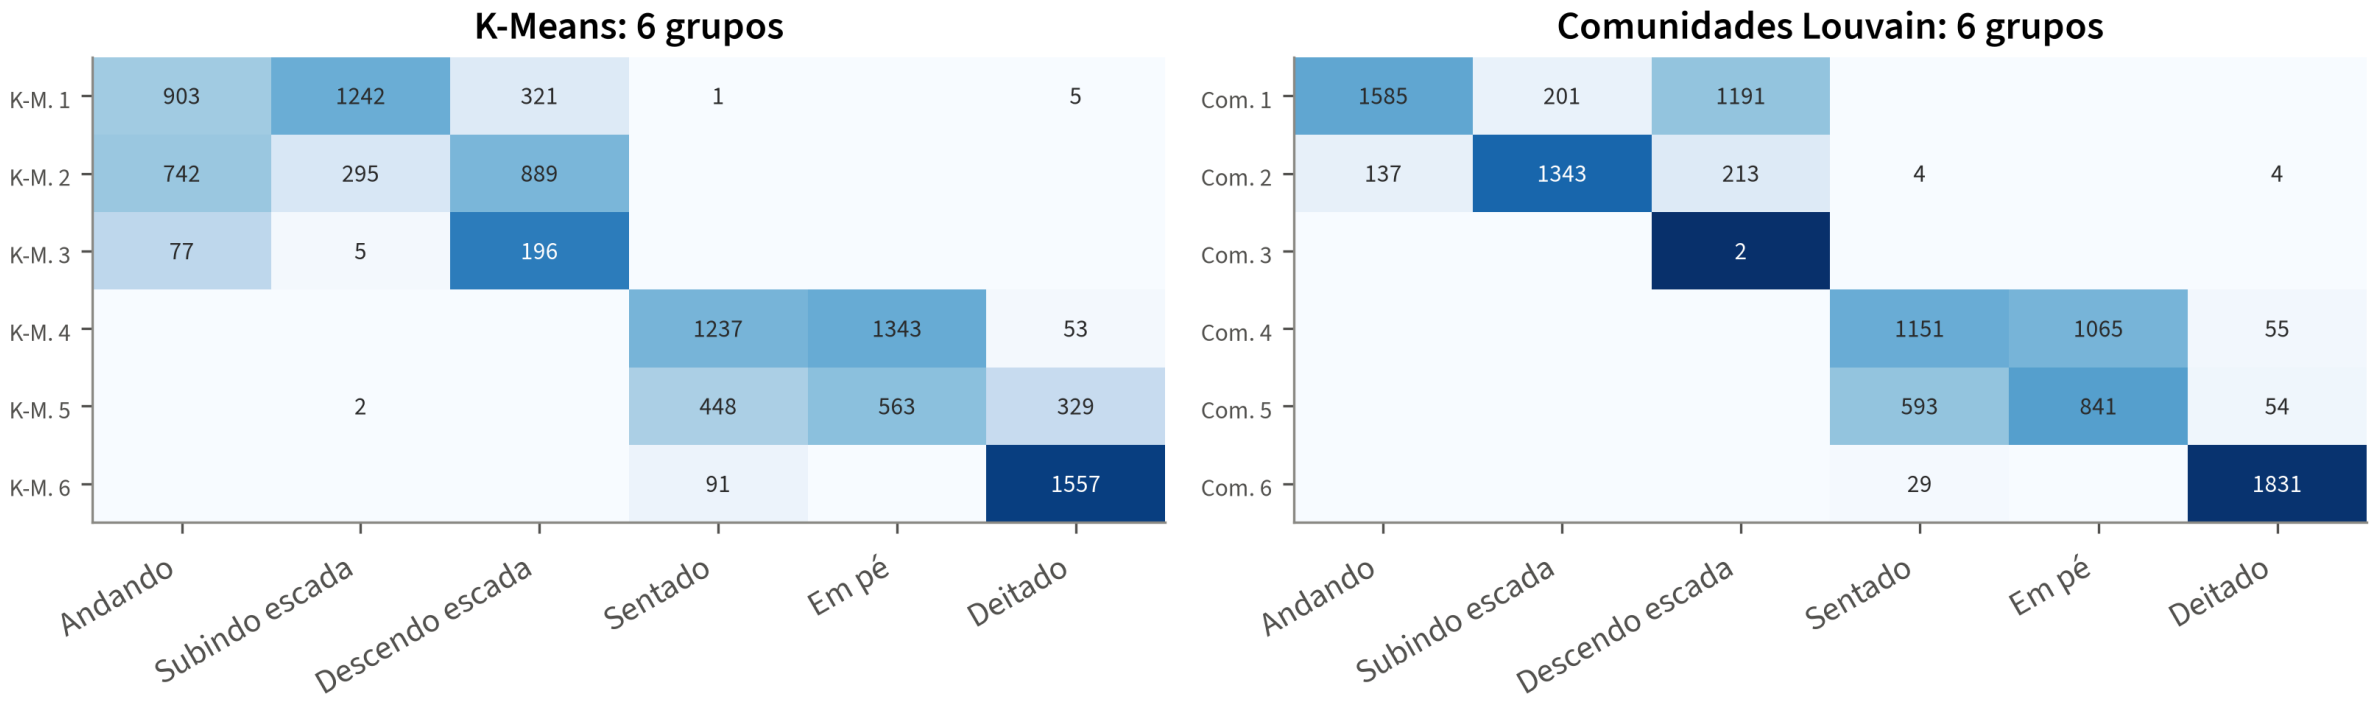


Comunidades Louvain (k = 100, 6 comunidades)



Cada grupo tem a cor da atividade mais comum nele; tons diferentes indicam grupos diferentes.

O que tem dentro de cada grupo



Número de janelas de cada atividade em cada grupo; cor = fração do grupo.

Comparação com as atividades reais

Comparação	ARI	NMI
K-Means × Atividade real	0,42	0,56
Comunidades × Atividade real	0,54	0,66
K-Means × Comunidades	0,61	0,71

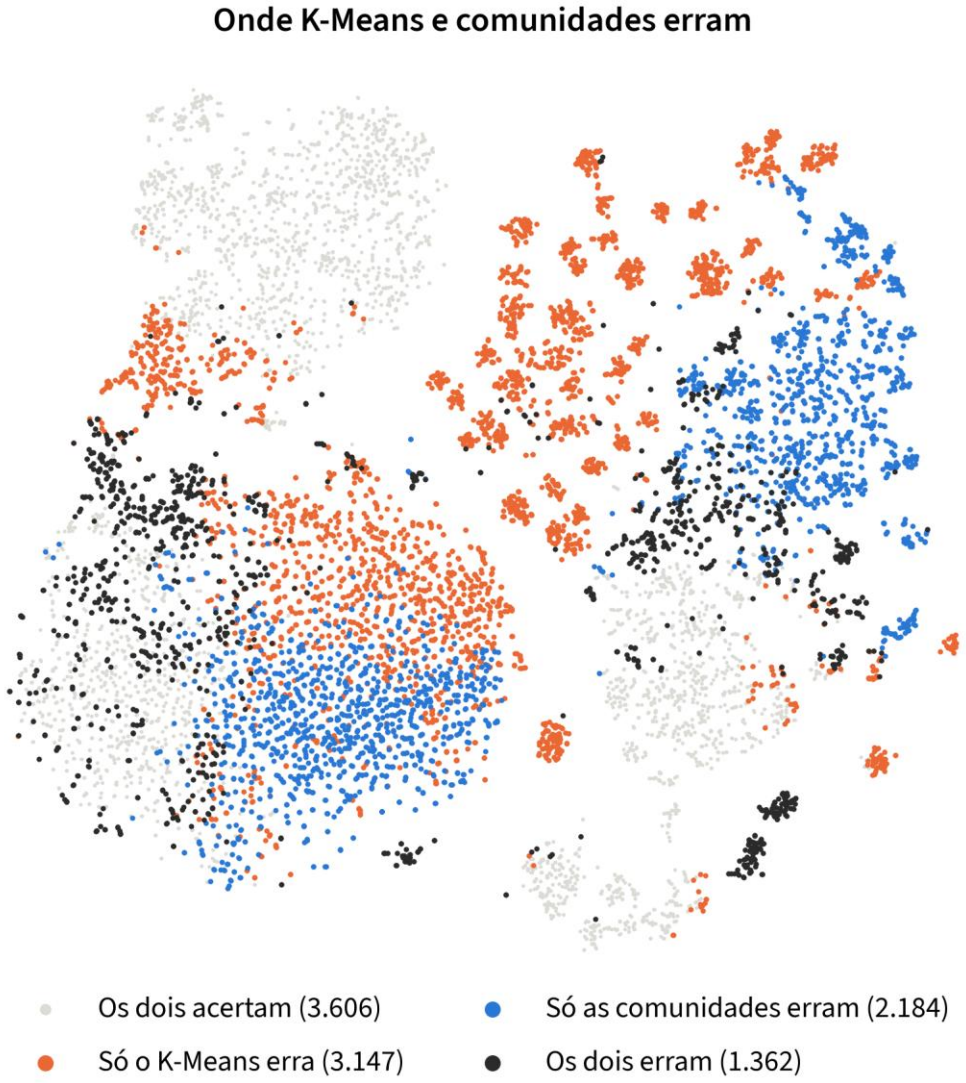
Partição	Grupos	Silhueta
Atividade real	6	0,03
K-Means	6	0,11
Comunidades	6	0,08

As duas abordagens acertam a divisão grossa e erram no mesmo lugar: Sentado × Em pé.

A silhueta das atividades reais é quase zero: no espaço de atributos, as classes não são grupos compactos.

Silhueta favorece o K-Means, que otimiza algo parecido com ela.

Onde os dois métodos erram



19%

dos vizinhos são de outra atividade, onde os dois erram

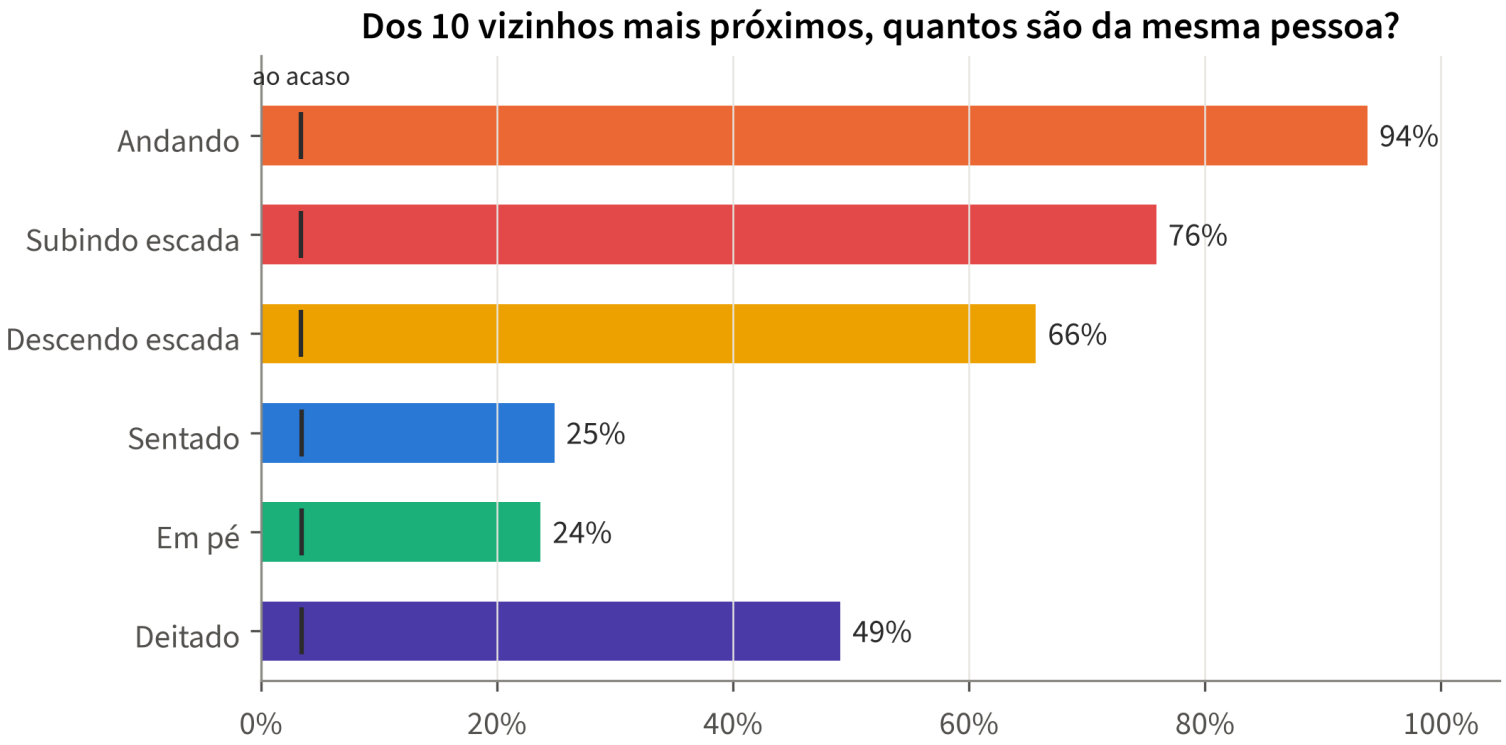
5%

onde os dois acertam

Acerto: a atividade mais comum do grupo é a atividade da janela.

Os erros em comum ficam nas fronteiras entre atividades, onde a vizinhança é misturada.

Achado: o jeito de andar é pessoal



94%

dos vizinhos de uma janela de Andando são da mesma pessoa (ao acaso: 3%)

90%

ignorando janelas próximas no tempo

Por isso, com k pequeno, o grafo separa Andando por pessoa (k = 10: NMI comunidade × pessoa = 0,79).

Parado, todo mundo é parecido. Andando, cada um tem seu ritmo: é a ideia por trás da identificação pela marcha.

Conclusões

As duas abordagens concordam no grosso

Movimento × parado e Deitado aparecem nas duas. ARI entre elas: 0,61.

Comunidades ligeiramente melhores

NMI com as atividades: 0,66 (comunidades) contra 0,56 (K-Means).

k controla a escala

k pequeno vê detalhes (pessoas); k grande vê só o geral. Q alto não quer dizer grupos úteis.

Os dados têm outra estrutura

Os grupos naturais nem sempre são os rótulos: aqui aparecem movimento × parado e as próprias pessoas.

Referências

BLONDEL, V. D. et al. Fast unfolding of communities in large networks. J. Stat. Mech., P10008, 2008.

FORTUNATO, S. Community detection in graphs. Physics Reports, v. 486, p. 75-174, 2010.

FORTUNATO, S.; BARTHÉLEMY, M. Resolution limit in community detection. PNAS, v. 104, n. 1, p. 36-41, 2007.

HUBERT, L.; ARABIE, P. Comparing partitions. Journal of Classification, v. 2, p. 193-218, 1985.

LLOYD, S. Least squares quantization in PCM. IEEE Trans. Inf. Theory, v. 28, n. 2, p. 129-137, 1982.

NEWMAN, M. E. J. Modularity and community structure in networks. PNAS, v. 103, n. 23, p. 8577-8582, 2006.

NEWMAN, M. E. J.; GIRVAN, M. Finding and evaluating community structure in networks. Phys. Rev. E, v. 69, 026113, 2004.

REYES-ORTIZ, J. et al. Human Activity Recognition Using Smartphones. UCI ML Repository, 2013. DOI 10.24432/C54S4K.

ROUSSEEUW, P. J. Silhouettes. J. Comput. Appl. Math., v. 20, p. 53-65, 1987.

TRAAG, V. A.; WALTMAN, L.; VAN ECK, N. J. From Louvain to Leiden. Scientific Reports, v. 9, 5233, 2019.

VAN DER MAATEN, L.; HINTON, G. Visualizing data using t-SNE. JMLR, v. 9, p. 2579-2605, 2008.

VINH, N. X.; EPPS, J.; BAILEY, J. Information theoretic measures for clusterings comparison. JMLR, v. 11, p. 2837-2854, 2010.

VON LUXBURG, U. A tutorial on spectral clustering. Statistics and Computing, v. 17, p. 395-416, 2007.

ZACHARY, W. W. An information flow model for conflict and fission in small groups. J. Anthropol. Res., v. 33, n. 4, p. 452-473, 1977.

Obrigado!

Código, figuras e tabelas: um comando, python src/main.py

Perguntas?

Anexo: as medidas usadas

Modularidade

$Q = (1/2m)\ \Sigma_{ij}\ [A_{ij} - k_i k_j/2m]\ \delta(c_i, c_j)$

Arestas dentro das comunidades menos o esperado num grafo aleatório com os mesmos graus.

Ganho de mover o vértice i para C

$\Delta Q \propto k(i, C) - tot(C) \cdot k_i / 2m$

k(i, C): peso das arestas de i para C. tot(C): soma dos graus de C.

ARI

Conta pares de pontos juntos/separados nas duas partições e desconta o acaso. 1 = iguais, 0 = acaso.

NMI

$NMI = 2\ I(U;V) / [H(U) + H(V)]$

Quanto saber o grupo de uma partição diz sobre a outra. Entre 0 e 1.